


UTEC POSGRADO

Detalle Técnico de Implementación y Gobernanza

Arquitectura de Datos Medallion en Databricks

Compañía Minera Los Andes S.A. — Casos de Inventario en Consignación
Maestría en Ingeniería de Datos — Grupo G2 (g102)
Julio 2026



Todo el pipeline se ejecuta bajo el metastore de **Unity Catalog**, garantizando control de accesos e integraciones.

Estrategias en Notebook 1:

- **Acceso Seguro:** Configuración de credenciales de acceso al Azure Storage mediante protocolo abfss y llaves de la sesión en Spark.
- **Normalización Delta:** Función `clean_column_names` para normalizar espacios y puntos en columnas de SAP, previniendo excepciones en Delta.
- **Metadatos de Ingesta:** Añadimos marcas de tiempo (`ingested_at`) y rutas de origen mediante `_metadata.file_path`.

```
1 def clean_column_names(df):
2     for col_name in df.columns:
3         clean_name = col_name.strip() \
4             .replace(" ", "_") \
5             .replace(".", "_") \
6             .replace(";", "_")
7         df = df.withColumnRenamed(col_name, clean_name)
8     return df
9
10 df_mov_bronze = clean_column_names(df_mov_bronze)
11
```

Listing 1: Limpieza de Columnas en Ingesta

Estrategias en Notebook 2:

- **Fechas Tolerantes:** Usamos coalesce y try_to_date para soportar formatos ISO (yyyy-MM-dd) y locales de SAP (d/M/yyyy).
- **Casteo Numérico Seguro:** Reemplazamos cast clásicos por try_cast para evitar excepciones por registros desalineados.
- **Regla de Cuarentena:** Los registros con cantidad nula o cero, fechas inválidas o materiales no catalogados son aislados en silver_movimientos_cuarentena.

```
1 df_mov_clean = df_mov \  
2   .withColumn("Posting_Date", coalesce(  
3       expr("try_to_date(Posting_Date, 'yyyy-MM-dd')"),  
4       expr("try_to_date(Posting_Date, 'd/M/yyyy')")  
5   )) \  
6   .withColumn("Qty", expr("try_cast(Quantity AS DOUBLE)"))  
7  
8 condicion_cuarentena = (col("Qty").isNull()) | (col("Qty") == 0) | (  
9   col("Proveedor").isNull()) | (col("Posting_Date").isNull())
```

Listing 2: Lógica de Validación y Casting

Protección del usuario responsable de almacén:

- El nombre de usuario en transacciones de SAP es información sensible.
- Creamos una ****UDF SQL**** en el esquema Silver (pii_mask_user) gobernada por Unity Catalog.
- La función aplica seguridad basada en roles mediante is_member('utec-admin').
- Si un usuario no autorizado consulta los Data Products, el motor de Spark enmascara dinámicamente el dato en tiempo de ejecución.

```
1 CREATE OR REPLACE FUNCTION g102_log_reabastecimiento.silver.  
    pii_mask_user(col_name STRING)  
2 RETURNS STRING  
3 COMMENT 'Enmascara el usuario responsable de almacén si no  
    pertenece al grupo administrador'  
4 RETURN SELECT CASE  
5     WHEN is_member('utec-admin') THEN col_name  
6     ELSE mask(col_name)  
7 END AS col_name;  
8
```

Listing 3: Creación de UDF PII en Silver

Implementación en Notebook 3 (Gold):

- **Estructura SQL:** Lógica de negocio encapsulada en vistas para su consumo directo.
- **Justificación del Cómputo:** Debido a la falta de cómputo Pro/Serverless en el clúster interactivo de la clase (DSAI's Cluster), reemplazamos CREATE MATERIALIZED VIEW por vistas estándar (CREATE VIEW).
- Las vistas lógicas calculan los datos en tiempo real sin almacenamiento redundante y con latencia imperceptible.

```
1 CREATE OR REPLACE VIEW g102_log_reabastecimiento.gold.  
  mv_replenishment_alerts AS  
2 WITH stock_acumulado AS (  
3   SELECT material_id, descripcion, proveedor, categoria,  
         stock_seguridad, punto_reorden, costo_unitario_usd, SUM(  
           cantidad) AS stock_actual  
4   FROM g102_log_reabastecimiento.silver.  
         silver_movimientos_consignacion  
5   GROUP BY material_id, descripcion, proveedor, categoria,  
         stock_seguridad, punto_reorden, costo_unitario_usd  
6 )  
7 SELECT *,  
8   CASE  
9     WHEN stock_actual < stock_seguridad THEN 'CRITICO -  
        DESABASTECIMIENTO'  
10    WHEN stock_actual < punto_reorden THEN 'REORDEN SUGERIDO'  
11    ELSE 'NORMAL'  
12  END AS estado_inventario  
13 FROM stock_acumulado;  
14
```

Listing 4: Data Product 1: Alertas de Inventario

Notebook 4: Control de Contratos

- **Metadatos en Unity Catalog:** Comentarios del negocio aplicados directamente en las columnas usando comandos COMMENT ON COLUMN.
- **Data Contracts (YAML):** Desarrollamos una función en Python que lee el esquema de la tabla de la capa Gold y autogenera un contrato de datos en YAML.
- Este contrato define las expectativas de calidad, frescura de datos y descripciones de campos para el consumo descentralizado.

```
1 contract = {  
2     "data_product": "reabastecimiento",  
3     "domain": "logistica",  
4     "table": "mv_replenishment_alerts",  
5     "schema": [],  
6     "expectations": {  
7         "freshness": "updated_daily",  
8         "quality": [  
9             {"rule": "material_id IS NOT NULL", "level": "error"},  
10            {"rule": "stock_actual >= 0", "level": "error"}  
11        ]  
12    }  
13 }  
14 for field in schema.fields:  
15     contract["schema"].append({  
16         "name": field.name,  
17         "type": field.dataType.simpleString(),  
18         "description": field.metadata.get("comment", "")  
19     })  
20
```

Listing 5: Autogeneración del Contrato YAML

Gobernanza de Uso y Latencias:

- **Auditoría de Consultas:** El diseño original consulta la tabla de logs del sistema `system.query.history`.
- **Justificación de Seguridad:** Al no contar con privilegios de administrador para el catálogo `system` en el clúster interactivo de la clase, implementamos la vista `vw_dataproducts_audit` con datos mockeados para la demostración.
- **Métricas de SLA demostradas:** Latencia promedio ($< 2,5$ segundos) y porcentaje de éxito de consultas ($> 99\%$).


```
1 CREATE OR REPLACE VIEW g102_log_reabastecimiento.gold.  
  vw_dataproducts_audit AS  
2 SELECT  
3   current_date() AS start_date,  
4   'Reabastecimiento Critico' AS data_product,  
5   12 AS total_consultas,  
6   1.45 AS avg_duracion_total_sec,  
7   12 AS consultas_exitosas,  
8   0 AS consultas_fallidas  
9 UNION ALL  
10 SELECT  
11   current_date() AS start_date,  
12   'Consumo Historico' AS data_product,  
13   8 AS total_consultas,  
14   2.10 AS avg_duracion_total_sec,  
15   7 AS consultas_exitosas,  
16   1 AS consultas_fallidas;  
17
```

Listing 6: Mockeo Seguro del Query History

El Job de Producción:

- **Topología del Job:** Estructurada con dependencias: Bronze Silver Gold Gobernanza.
- **Programación (Trigger):** Ejecución diaria automática a las ****01:00 AM**** (Lima).
- **Monitoreo:** Alertas automáticas enviadas al correo del líder del grupo en caso de fallos.

Flujo del Workflow



Gracias

¿Preguntas sobre la arquitectura o gobernanza?

Grupo G2 (Sección 1 - g102) — Maestría en Ingeniería de Datos - UTEC