

UTEC POSGRADO – EXAMEN FINAL
Defensa Técnica de Arquitectura y Gobernanza
Pipeline Medallion Resiliente y Descentralizado

Compañía Minera Los Andes S.A. — Casos de Inventario en Consignación
Grupo G2 (Sección 1 - g102)
Julio 2026



Estructura de
almacenamiento distribuido sobre **Delta Lake** y controlada por políticas de **Unity Catalog**.

Notebook 1 - Bronze:

- **Ingesta Inmutable:** Carga los archivos CSV de SAP tal como vienen desde el Storage de Azure.
- **Normalización Delta:** Convierte caracteres especiales, espacios y puntos de SAP a guiones bajos para prevenir excepciones.
- **Delimitador SAP:** Configuración del lector con delimitador “;” o “,” para evitar desalineación de columnas en Spark.

```
1 # Lectura de datos en Bronze
2 df_movimientos_raw = spark.read.format("csv") \
3     .option("header", "true") \
4     .option("delimiter", ";") \
5     .option("inferSchema", "true") \
6     .load("abfss://.../raw/airflow/G2/MB51_*.csv")
7
8 # Estandarizar nombres de columnas para Delta Lake
9 def clean_column_names(df):
10     for col in df.columns:
11         clean = col.strip().replace(" ", "_").replace(".", "_")
12         df = df.withColumnRenamed(col, clean)
13     return df
14
15 df_bronze = clean_column_names(df_movimientos_raw) \
16     .withColumn("ingested_at", current_timestamp())
17
```

Listing 1: Carga y Normalización en Bronze

Notebook 2 - Silver:

- **Tolerancia a Fechas:** Intento de casteo a múltiples formatos de SAP (ISO y local regional) mediante coalesce.
- **Casteo Numérico Resiliente:** Uso de try_cast para evitar excepciones por registros desalineados.
- **Control de Signos de Movimiento:** Estandarización de cantidades (positivo para entradas 101/511, negativo para consumos 201/261).

```
1 # Parsing tolerante de fechas y casting
2 df_clean = df_bronze.withColumn("Posting_Date", coalesce(
3     expr("try_to_date(Posting_Date, 'yyyy-MM-dd')"),
4     expr("try_to_date(Posting_Date, 'd/M/yyyy')")
5 )).withColumn("Qty", expr("try_cast(Quantity AS DOUBLE)"))
6
7 # Mapear signo seg n tipo de movimiento SAP
8 df_silver = df_clean.withColumn("cantidad",
9     when(col("Movement_Type").isin("101", "511"), abs(col("Qty")))
10    .when(col("Movement_Type").isin("201", "261"), -abs(col("Qty")))
11    .otherwise(col("Qty"))
12 )
13
```

Listing 2: Tratamiento de Signos y Fechas

Diagnóstico de la Falla del Join:

- **El Síntoma:** 233.69K registros caían en la tabla de cuarentena y los Data Products quedaban vacíos.
- **La Causa:** SAP almacena códigos de material con ceros a la izquierda (ej. '000000000000100243'), mientras que el maestro de materiales los tenía sin ceros ('100243'). El join fallaba, y el campo 'Proveedor' era nulo.
- **La Solución:** Aplicar `ltrim(col, "0")` en ambas fuentes antes de unir.

```
1 from pyspark.sql.functions import ltrim, col
2
3 # Estandarizar claves eliminando ceros a la izquierda
4 df_mov_clean = df_mov_clean.withColumn(
5     "Material_Join",
6     ltrim(col("Material"), "0")
7 )
8 df_maestro_clean = df_maestro.withColumn(
9     "Material_Join",
10    ltrim(col("Material"), "0")
11 )
12
13 # Join por clave unificada para evitar proveedor nulo
14 df_joined = df_mov_clean.join(
15     df_maestro_clean,
16     "Material_Join",
17     "left"
18 )
19
```

Listing 3: Solución al Join con ltrim

Inferencia de Saldos Iniciales:

- **El Problema:** El pipeline calcula el stock actual de forma acumulativa. Sin una foto de saldos iniciales (saldo de apertura), las salidas iniciales restaban de '0' generando stocks negativos virtuales.
- **La Solución:** Generar virtualmente los saldos iniciales en Bronze ('Movimiento 561') al 31 de Mayo, y hacer un `union` antes del procesamiento en Silver.

```
1 # Crear saldos iniciales de apertura en la v spera
2 data_saldos = [
3     ("100243", "2026-05-31", 180.0, 0.0, "561", "K", "ALM1", "
4         SYS_INIT"),
5     ("100244", "2026-05-31", 250.0, 0.0, "561", "K", "ALM1", "
6         SYS_INIT")
7 ]
8 df_saldos = spark.createDataFrame(data_saldos, schema=schema_saldos)
9
10 # Unir saldos y movimientos del mes en Silver
11 df_total_movimientos = df_movimientos.union(df_saldos_iniciales)
12
13 # La suma acumulativa en Gold ahora parte de una base positiva
```

Listing 4: Integración de Saldos Iniciales en Bronze

Gobernanza de Datos Sensibles:

- **Dato Sensible:** El nombre del operador del almacén de SAP es información confidencial.
- **UDF por Roles:** Creamos la UDF SQL `pii_mask_user` en Unity Catalog.
- **Control de Acceso:** Si el usuario consultor no pertenece al grupo de administradores, el motor enmascara dinámicamente el dato en tiempo de ejecución.

```
1 CREATE OR REPLACE FUNCTION g102_log_reabastecimiento.silver.  
    pii_mask_user(col_name STRING)  
2 RETURNS STRING  
3 COMMENT 'Enmascara el usuario si no es administrador'  
4 RETURN SELECT CASE  
5     WHEN is_member('utec-admin') THEN col_name  
6     ELSE mask(col_name)  
7 END AS col_name;  
8  
9 -- Aplicación en la vista de consumo  
10 -- SELECT pii_mask_user(User_Name) AS usuario_masked ...  
11
```

Listing 5: UDF SQL de Enmascaramiento PII

Modelamiento Semántico:

- **DP1: Reabastecimiento Crítico**
(mv_replenishment_alerts). Muestra qué comprar basándose en stock actual, stock de seguridad y punto de reorden.
- **DP2: Análisis de Consumo**
(mv_consumption_analysis). Costo acumulado agrupado por período y categoría.
- **DP3: Conciliación de Pagos**
(mv_monthly_conciliation). Agrupación contable por Documento de Material SAP.

```
1 CREATE OR REPLACE VIEW g102_fin_conciliacion.gold.  
  mv_monthly_conciliation AS  
2 SELECT  
3   date_format(fecha_movimiento, 'yyyy-MM') AS anio_mes,  
4   proveedor,  
5   documento_material,  
6   material_id,  
7   descripcion,  
8   costo_unitario_usd,  
9   ABS(SUM(cantidad)) AS cantidad_facturable,  
10  ABS(SUM(monto_total_usd)) AS monto_facturable_usd  
11 FROM g102_log_reabastecimiento.silver.  
  silver_movimientos_consignacion  
12 WHERE cantidad < 0  
13 GROUP BY 1, 2, 3, 4, 5, 6;  
14
```

Listing 6: Consolidación en Gold (DP3)

Gobernanza de Producto:

- **Metadatos Integrados:** Definición de columnas inyectada directamente al catálogo con COMMENT ON COLUMN de SQL.
- **Contratos YAML:** Función en Python que lee el esquema Delta de Gold y autogenera un contrato YAML con las expectativas de frescura y calidad para los consumidores.

```
1 # Estructuración de Contrato YAML en Python
2 contract = {
3     "data_product": "reabastecimiento",
4     "domain": "logística",
5     "schema": [],
6     "expectations": {
7         "freshness": "updated_daily",
8         "quality": [{"rule": "material_id IS NOT NULL"}]
9     }
10 }
11 for field in df_gold.schema.fields:
12     contract["schema"].append({
13         "name": field.name,
14         "type": field.dataType.simpleString(),
15         "description": field.metadata.get("comment", "")
16     })
17
```

Listing 7: Función Autogeneradora de Contratos

Monitoreo de SLAs de Consulta:

- **Métricas de SLA:** Latencia promedio (< 2,5 segundos) y porcentaje de éxito de consultas (> 99 %).
- **Seguridad de Catálogo:** Al no contar con privilegios en la tabla del sistema `system.query.history` en la interfaz interactiva, se mockeó el reporte con datos representativos realistas de uso de los Data Products.


```
1 CREATE OR REPLACE VIEW gold.vw_dataproducts_audit AS
2 SELECT
3     current_date() AS start_date,
4     'Reabastecimiento Critico' AS data_product,
5     12 AS total_consultas,
6     1.45 AS avg_duracion_total_sec,
7     12 AS consultas_exitosas,
8     0 AS consultas_fallidas
9 UNION ALL
10 SELECT
11     current_date() AS start_date,
12     'Consumo Historico' AS data_product,
13     8 AS total_consultas,
14     2.10 AS avg_duracion_total_sec,
15     7 AS consultas_exitosas,
16     1 AS consultas_fallidas;
17
```

Listing 8: Estructura de la Vista de Auditoría

Topología del Job:

- **Secuenciación de Tareas:** Bronze → Silver → Gold → Gobernanza.
- **Programación (Trigger):** Ejecución diaria automatizada a las ****01:00 AM**** (Lima).
- **Alertas de Fallo:** Envío de notificaciones por correo automatizadas en caso de caída de tareas.

Flujo del Workflow



Gracias

¿Preguntas sobre el pipeline técnico?

Grupo G2 (Sección 1 - g102) — Maestría en Ingeniería de Datos - UTEC