

Proyecto Integrador

Maestría	: Ciencia de datos e Inteligencia Artificial
Curso	: Ingeniería de Datos
Docente	: Mg. Angel Tintaya Monroy
Formato de trabajo	: Grupal, de 5 personas

Durante el curso se desarrollará un proyecto integrador en dos etapas: Avance y Proyecto Final. A través de este proyecto, los grupos deberán aplicar los conceptos teóricos y prácticos aprendidos en clase, enfocándose en el diseño, automatización y exposición de un flujo de datos en la nube. El objetivo principal es fomentar una visión práctica pero estructurada, que simule cómo un equipo de ingeniería de datos colabora en un entorno profesional.

Nota: No se espera un desarrollo técnico complejo ni arquitecturas avanzadas. La prioridad es el entendimiento conceptual, la reflexión crítica y el valor aportado al negocio.

Avance

Planteamiento del Avance

Durante esta primera etapa, los alumnos deberán construir un pipeline de datos utilizando Apache Airflow. Este pipeline deberá mover datos desde un servidor simulado (archivos en una carpeta local) hasta un contenedor Raw en Azure Data Lake.

Este proyecto busca que los estudiantes apliquen conceptos clave de ingestión de datos, orquestación de pipelines, y conexión con servicios en la nube. No se espera una arquitectura compleja, pero sí una implementación técnica sólida que respete buenas prácticas vistas en clase.

Guía del Avance

1. Contexto del proyecto:
 - a. ¿Qué problema de negocio están resolviendo?
 - b. ¿Qué tipo de datos están ingiriendo y por qué?
 - c. ¿Por qué es importante automatizar esta carga?
2. Diseño Arquitectónico (conceptual, no técnico)
 - a. Diagrama general del flujo de datos
(fuente → orquestador → almacenamiento).
 - b. Identificación de los componentes principales.

- c. Justificación de las decisiones (por qué se eligieron los componentes)
3. Pipeline de ingesta:
 - a. Descripción del flujo: extracción, transformación mínima (si aplica), y carga.
 - b. Descripción del DAG: tareas principales y frecuencia de ejecución.
 - c. Descripción de errores que podría manejar y cómo.
4. Uso de Git (Control de versiones)
 - a. Subir el código a un repositorio de GitHub
 - b. Uso de ramas utilizando Gitflow
5. Presentación (en clase)
 - a. Presentación del avance
 - b. Recomendaciones: No mostrar código, pero sí resultados, arquitectura, visión.

Entregables del Avance

- Presentación parcial (avance del proyecto, máximo 15 slides).
- Repositorio en GitHub con DAG funcional y estructura clara.

Criterios de Evaluación

Se considerarán los siguientes criterios:

Criterio	Descripción	Peso
Planteamiento del problema y contexto	Claridad al explicar el problema de negocio y su relevancia.	25%
Diseño del pipeline y arquitectura conceptual	Coherencia y justificación del flujo de datos y sus componentes.	20%
Pipeline funcional	Se evalúa si el DAG se ejecuta con éxito.	20%
Presentación clara y estructurada	Claridad en la presentación, enfoque estructurado (No código).	15%
Uso de Git y documentación básica	Buen manejo de repositorio y README explicativo.	20%