



UTEC Posgrado

CURSO

INGENIERÍA DE DATOS

Mg. Angel Tintaya
Senior Data Engineer



The background of the image features a dark blue field with a glowing network of white lines and dots, resembling a data or neural network. In the lower foreground, a human hand is visible, with the index finger pointing towards the left, where a bright, glowing light source is located. The text is centered in the upper half of the image.

ARQUITECTURA Y ESTRATEGIA DE DATA ENGINEERING




FUNDAMENTOS DE DATA ENGINEERING

**¿Qué tan grave sería
para tu empresa tomar
decisiones con datos
incorrectos durante
una semana?**



Qué aprenderemos hoy


- Qué es realmente Ingeniería de Datos
- Por qué es crítico para el negocio
- Cómo ha evolucionado el rol
- Qué hace un Ingeniero de Datos en la práctica
- Comprender la madurez de datos en las organizaciones






AGENDA DE HOY

- The journey begins
- El problema real de los datos en las organizaciones
- Qué es Ingeniería de Datos
- Cómo funciona en la práctica
- El rol del Ingeniero de Datos
- Madurez de datos en empresas





The journey
begins



- **Fundamentos de Data Engineering**
- Diferencias entre Data Engineering, Data Discovery y Data Science
- Arquitecturas modernas de datos: Data Warehouses, Data Lakes y Lakehouse
- Data Mesh y Data Fabric: enfoques descentralizados de gestión de datos
- Patrones de ingestión de datos: Batch, Streaming y Lambda/Kappa Architectures



El problema de los datos en las organizaciones

¿Por qué teniendo tantos datos, las empresas siguen tomando malas decisiones?



Problemas clásicos



**Datos
inconsistentes**



**Procesos
Ineficientes**



**Falta de
escalabilidad**



**Seguridad y
cumplimiento**





¿Qué es Ingeniería de Datos?

Definiciones clave

”Ingeniería de datos es un conjunto de operaciones que apoyan en la creación de interfaces y mecanismos para el flujo y acceso de información...”

Fuente: Data Engineering and Its Main Concepts, AlexSoft (2021)

”Ingeniería de datos es todo lo relacionado al movimiento, manipulación y administración de la data.”

Fuente: What is Data Engineering, Lewis Gavin (2020)



¿Qué es ingeniería de datos?

La ingeniería de datos consiste en el desarrollo, la implementación, y en el mantenimiento de sistemas y procesos que toman datos sin procesar y generan información consistente y de alta calidad que respalda casos de uso posteriores, como son el análisis y el machine learning. La ingeniería de datos es la intersección entre la seguridad, la gestión de datos, las operaciones de datos, la arquitectura de datos, la orquestación y la ingeniería de software.

Fuente: Fundamentals of Data Engineering, Joe Reis (2023)



¿Qué es ingeniería de datos?

La ingeniería de datos consiste en **el desarrollo, la implementación, y en el mantenimiento** de sistemas y procesos que toman datos sin procesar y **generan información consistente y de alta calidad** que respalda casos de uso posteriores, como son el análisis y el machine learning. La ingeniería de datos es la **intersección** entre la seguridad, la gestión de datos, las operaciones de datos, la arquitectura de datos, la orquestación y la ingeniería de software.

Fuente: Fundamentals of Data Engineering, Joe Reis (2023)




¿Cuál es la relación entre la ingeniería de datos y la ciencia de datos?



Ingeniería de datos y la ciencia de datos

Ambos **se complementan**, pero son disciplinas distintas.
La Ingeniería de Datos es el pilar que permite a la Ciencia de Datos
convertir datos en conocimiento útil.




```
__ ==  
= str(sys.argv[1]) #  
t_date = str(sys.argv[2]) # '20190901'  
  
= int(target_date[0:4])  
th = int(target_date[4:6])  
y = int(target_date[6:8])  
target_date = datetime.date(year, month, day)  
wb = Workbook()  
ws = wb.active  
ws.title = "Hotel list"  
initializeSheet(ws)  
  
for term in range(0,7):  
    i in range(1, 7): #  
        call(s_area, target_date
```

Imagina que una empresa quiere hacer predicciones de demanda con IA, pero los datos están desordenados y llegan con errores.

¿Qué pasaría?

La Jerarquía de Necesidades de Ciencia de Datos






¿Han tenido que trabajar con datos sucios o encontrar datasets inconsistentes? ¿Cómo impacta esto en los modelos?



Solución: El rol del ingeniero de datos

Los ingenieros de datos permiten que la ciencia de datos sea productiva y escalable.



Imaginemos una empresa con millones de transacciones diarias.



¿Cómo garantizar que los datos estén listos para modelos de predicción?



Sin ingeniería de datos:

Modelos ineficientes y problemas en producción.

Con ingeniería de datos:

Ciencia de datos escalable, reproducible y confiable.



A photograph of three professionals standing on a modern, wide staircase. On the left, a man with a beard and mustache, wearing a blue blazer over a light blue shirt and dark trousers, stands with his hands in his pockets. In the center, a woman with long dark hair, wearing a light grey blazer over a yellow top and dark blue trousers, stands with her hands on her hips. On the right, a man with short dark hair, wearing a light blue blazer over a light blue shirt and dark trousers, stands with his hands in his pockets. The staircase is made of light-colored concrete steps and has a metal railing on the right side. The background is a modern building with large concrete pillars and a staircase. The text "Cómo funciona en la práctica" is overlaid in white, bold, sans-serif font across the center of the image.

Cómo funciona en la práctica

**Desde que se generan
los datos en distintas
áreas hasta que alguien
toma una decisión...
¿qué pasos creen que
ocurren?**






Más allá de la tecnología ...

... un enfoque de los
datos
y sus objetivos


De la generación al consumo de datos



Las cinco etapas del ciclo de vida



Las cinco etapas del ciclo de vida



Las cinco etapas del ciclo de vida

Generación

Ejemplos: Bases de datos, sensores IoT, registros de transacciones, APIs, logs

Riesgos: Datos incompletos, formatos inconsistentes

Almacenamiento

Ejemplos: Bases de datos, Data Lakes, Data Warehouses

Riesgos: Elección inadecuada de almacenamiento que impacta en rendimiento/costo

Ingestión

Ejemplos: Streaming, Batch, Pipelines

Riesgos: Latencia, fallos en la extracción, pérdida de datos

Transformación

Ejemplos: Procesos de ETL/ELT, limpieza, normalización

Riesgos: Datos incorrectos afectan modelos y análisis

Consumo

Ejemplos: Dashboards, reportes, APIs, modelos de ML, Reverse ETL

Riesgos: Si no hay buen diseño, el acceso a los datos es lento o ineficiente

¿En qué parte del ciclo de vida se pierde más valor en tu empresa?



Problemas clásicos en el ciclo de vida



**Datos
inconsistentes**



**Procesos
Ineficientes**



**Falta de
escalabilidad**



**Seguridad y
cumplimiento**



Undercurrents – Los Hilos Invisibles

Factores transversales que impactan todas las fases:

Seguridad

Gestión de Datos

DataOps

Arquitectura de
Datos

Orquestación

Ingeniería de
Software



Undercurrents – Los Hilos Invisibles

Factores transversales que impactan todas las fases:

Protección de accesos,
encriptación, auditoría

Calidad, metadata,
gobernanza

Automatización, monitoreo,
CI/CD

Modelado,
particionamiento,
escalabilidad

Coordinación de flujos de
trabajo: Dependencias,
ejecución, programación

Testing, versionado,
modularidad



UTEC VENTURES

El rol del ingeniero de datos

PANEL UV


UIS 20

UTEC
VENTURES

**¿Qué herramientas,
tecnologías o
conceptos asocias con
Ingeniería de Datos?**



Resultado



¿Qué hace un ingeniero de datos?

¿Qué hace? 	¿Qué no hace? 
Construcción de pipelines de datos eficientes.	No entrena modelos de ML.
Gestión y optimización del almacenamiento y procesamiento.	No hace reportes ni dashboards.
Seguridad y gobernanza de datos.	No desarrolla aplicaciones completas.
Integración con herramientas de análisis y ML.	No define KPIs ni realiza análisis de negocio.

... sin embargo, debe tener conocimiento de estas areas para servirlas mejor.



El Equilibrio de la Ingeniería de Datos

Un ingeniero de datos debe garantizar el equilibrio entre:

Costo

Agilidad

Escalabilidad

Simplicidad

Reuso

Interoperabilidad



El Equilibrio de la Ingeniería de Datos

Un ingeniero de datos debe garantizar el equilibrio entre:

Balance entre soluciones económicas y rendimiento adecuado.

Implementación rápida sin comprometer estabilidad.

Manejo eficiente del crecimiento del volumen de datos.

Evitar arquitecturas excesivamente complejas.

Aprovechar componentes existentes en vez de reinventar la rueda.

Capacidad de integrarse con múltiples herramientas y sistemas.



La evolución del ingeniero de datos

Antes (Monolítico)	Ahora (Ágil y Modular)
Hadoop, Spark, Hive	Servicios cloud escalables (AWS, GCP, Azure)
Clusters complejos	Pipelines gestionados (Databricks, Snowflake)
Administración manual	DataOps y automatización
Infraestructura pesada	Soluciones serverless y gestión simplificada



La ruta para convertirse en ingeniero de datos

No existe una trayectoria standard de ingeniero de datos, pero la transición es sencilla si se viene de:



Ingeniería de software



Analista de datos



Administrador de BD



Lo que realmente necesitas aprender ...



SQL



Python



Bash



JVM



Gestión de datos



Arquitectura de datos

La clave del éxito en ingeniería de datos **NO** es la tecnología, sino la visión empresarial y técnica combinada.



Tu empresa necesita mover datos de un sistema legacy a la nube. ¿Qué factores considerarías?

Opción A

Una solución rápida
pero costosa


Opción B

Una solución
escalable pero lenta
de implementar

Opción C

Una solución barata
pero sin soporte a
largo plazo

Madurez de los datos y su impacto



¿Qué es la madurez de los datos?

- Es la progresión hacia un mayor uso, integración y aprovechamiento de los datos en una organización.
- No depende del tamaño ni de los ingresos de la empresa.




**Startup
Fintech**



**Banco
Tradicional**



Evolución de la madurez de los datos?



Fase 1: Empezar con los datos

- Falta de objetivos claros.
- Infraestructura y arquitectura en etapa inicial.
- Poca utilización de datos.
- El Ingeniero de Datos es generalista y hace de todo (ETL, ML, software...).



Error común: Intentar hacer Machine Learning sin tener una base sólida en datos



Consejo práctico: “Si no puedes responder preguntas básicas del negocio con datos, no intentes hacer ML todavía.”



Objetivo DE: Avanzar rápido, Conseguir impulso y añadir valor



Fase 2: Escalar con los datos

- Se crean arquitecturas escalables.
- La ingeniería de datos se especializa (DEs con distintos enfoques).
- Se aplican prácticas como DataOps y CI/CD para datos.
- **Cuello de botella:** El equipo de DE es el único que sabe cómo usar los datos.



Consejo práctico: “Cualquier decisión tecnológica debe estar motivada por el valor que aportará a sus clientes.”



Consejo práctico: “Enseñe a la organización a consumir y aprovechar los datos.”



Fase 3: Dirigir con los datos

- La empresa usa autoservicio de datos y ML con facilidad.
- Pipelines automatizados garantizan disponibilidad y calidad.
- El Ingeniero de Datos ya no solo construye, sino que gestiona **gobernanza, calidad y linaje** de datos.



**¿Dónde está tu
empresa hoy en
este modelo?**



Takeaways

- Sin Ingeniería de datos, los datos no generan valor
- El problema no es tener datos, es gestionarlos bien
- El Ingeniero de Datos habilita decisiones, no análisis
- La madurez de datos define la capacidad de una empresa
- Escalabilidad, costo y simplicidad siempre están en tensión

¡Gracias!



UTEC Posgrado