



UTEC Posgrado

CURSO


INGENIERÍA DE DATOS

Mg. Angel Tintaya
Senior Data Engineer



The background features a dark blue gradient with a glowing white network of interconnected nodes and lines on the left side. A hand is visible at the bottom, with the index finger pointing towards the left, where a bright light source creates a lens flare effect.

ARQUITECTURA Y ESTRATEGIA DE DATA ENGINEERING



ARQUITECTURAS MODERNAS DE DATOS

Si tu empresa tuviera todos sus datos...



¿eso garantiza que
pueda tomar mejores
decisiones?




Qué aprenderemos hoy

- Qué es una arquitectura de datos
- Diferencias entre Data Warehouse, Data Lake y Lakehouse
- Cuándo usar cada una
- Cómo impactan en el negocio
- Cómo elegir una arquitectura según el caso




AGENDA DE HOY

- The road so far
- El problema de los datos en las organizaciones
- Data Warehouse
- Data Lake
- Lakehouse
- Comparación y toma de decisiones
- Caso aplicado






The road so far



- Fundamentos de Data Engineering
- Diferencias entre Data Engineering, Data Discovery y Data Science
- **Arquitecturas modernas de datos: Data Warehouses, Data Lakes y Lakehouse**
- Data Mesh y Data Fabric: enfoques descentralizados de gestión de datos
- Patrones de ingestión de datos: Batch, Streaming y Lambda/Kappa Architectures



El problema de los datos en las organizaciones

The background image shows a modern office space with large glass windows and doors. Inside, there are desks, chairs, and various office equipment. The text "El problema de los datos en las organizaciones" is overlaid in a large, white, sans-serif font. The office interior is visible through the glass, showing a clean and professional environment. The floor is made of polished concrete, and the walls are white. The lighting is bright and even, highlighting the office's layout and the text overlay.

¿Por qué una empresa con muchos datos no necesariamente es data-driven?




¿Qué es una arquitectura de datos?

Una arquitectura de datos es un **conjunto de estándares**, estructuras y modelos que permiten la **captura, almacenamiento, integración, distribución y consumo de datos dentro de una organización**, alineando el uso de datos con los objetivos del negocio.



¿Qué es una arquitectura de datos?

**Arquitectura
de datos**



**Cómo organizas los
datos para generar
valor**



Online Transaction Processing - OLTP

- Es un modelo de procesamiento de datos diseñado para soportar **transacciones rápidas y concurrentes** que actualizan datos con **baja latencia**. Se usa típicamente en sistemas operacionales como ERP, CRM o sistemas bancarios.
- En OLTP, los **datos se normalizan** para **minimizar la redundancia** y garantizar **integridad**. El enfoque está en rendimiento para operaciones tipo INSERT, UPDATE y DELETE.



Online Analytical Processing - OLAP

Es una categoría de **herramientas y bases de datos** diseñadas para realizar **análisis complejos** y multidimensionales de grandes volúmenes de datos, **optimizando** el rendimiento de **consultas agregadas**.



Está desacoplado del sistema transaccional.



OLTP y OLAP - Características

Características	OLTP	OLAP
Objetivo	Operaciones del día a día	Análisis e informes
Tipos de datos	Transaccionales	Agregados e históricos
Frecuencia de acceso	Alta	Baja (pero consultas complejas)
Diseño	Normalizado	Desnormalizado (modelos star/snowflake)



A photograph of three people—two men and one woman—standing on a wide, modern concrete staircase. The man on the left is wearing a blue blazer over a light blue shirt and dark trousers. The woman in the center is wearing a light grey blazer over a yellow top and dark trousers. The man on the right is wearing a light blue blazer over a light blue shirt and dark trousers. They are all smiling and looking towards the camera. The background is a modern building with concrete walls and stairs. The text "Data Warehouse" is overlaid in the center in a large, white, sans-serif font.

Data Warehouse

¿Qué pasa si quiero analizar datos confiables y estructurados?



¿Qué es un Data Warehouse?

Un Data Warehouse es una **base de datos corporativa** orientada al **análisis, integrada, no volátil** y con una **perspectiva histórica**, que apoya el proceso de toma de decisiones.

Bill Inmon


Un Data Warehouse es una **copia de datos transaccionales** estructurados específicamente para consultas y análisis.

Ralph Kimball,
The Data Warehouse Toolkit



Características

- Datos estructurados y de calidad
- Optimizado para consultas analíticas (OLAP)
- Modelado dimensional (star/snowflake schema)
- Batch ingestion (datos periódicos)
- Centralizado y gobernado



Enfoques de modelado - Inmon vs. Kimball

Criterio	Inmon	Kimball
Filosofía	Top-down (empresa)	Bottom-up (necesidad)
Modelo	3NF corporativa	Dimensional (star/snowflake)
Implementación	Lenta pero robusta	Rápida y enfocada
Ideal para	Gobierno y consistencia	Agilidad y usuarios finales

Usos: Reportes financieros, Dashboards ejecutivos, KPI corporativos


Ejemplos: BigQuery, Snowflake, Amazon Redshift



Dimensional Data Models

Star Schema


Es un modelo de diseño dimensional para data warehouses en el que una **tabla de hechos central** se conecta directamente a múltiples **tablas de dimensiones desnormalizadas**. Su estructura simple y eficiente **permite consultas rápidas**, ideal para análisis y reportes empresariales.



Dimensional Data Models

Snowflake Schema

Es una variante del Star Schema donde las **tablas de dimensiones están normalizadas** en múltiples niveles jerárquicos. Este modelo **minimiza la redundancia** y mejora la integridad de los datos, aunque **incrementa la complejidad** de las consultas.



¿Qué pasaría si necesito agregar datos nuevos rápidamente?



Data Warehouse - Ventajas y Desventajas

Ventajas

- **Centralización de la información:** integra datos de múltiples fuentes.
- **Mejora la toma de decisiones:** facilita el análisis histórico y tendencias.
- **Alta velocidad en consultas analíticas:** optimizado para OLAP.
- **Calidad y consistencia de datos:** validación, limpieza y reglas unificadas.
- **Soporte para BI y reportes:** fácil integración con Power BI, Tableau, etc.
- **Seguridad y control de acceso:** políticas claras sobre quién accede a qué.

Desventajas

- **Costo inicial elevado:** implementación y mantenimiento pueden ser costosos.
- **Complejidad técnica:** requiere diseño, modelado y conocimientos especializados.
- **No apto para transacciones operativas:** no reemplaza un sistema OLTP.
- **Tiempo de carga:** ETL puede ser lento si no está bien optimizado.
- **Rigidez ante cambios:** agregar nuevas fuentes o métricas requiere rediseño.
- **Latencia:** los datos no siempre están en tiempo real.

A photograph of two women in an office environment, smiling and looking at a computer screen. The woman on the left is partially visible, smiling broadly. The woman on the right is shown in profile, pointing at the screen. The background is slightly blurred, showing office equipment and another person. The text 'Data lake' is overlaid in white on a dark semi-transparent background.

Data lake

¿Y si quiero guardar TODO tipo de datos?



¿Qué es un Data Lake?

Un Data Lake adquiere **datos de diversas fuentes** dentro de la empresa en su **forma nativa** y también puede tener versiones internas modeladas de estos mismos datos para diversos fines. La información manejada puede ser de cualquier tipo, desde **datos estructurados o semiestructurados hasta datos completamente no estructurados**.

Tomcy John, Pankaj Misra, Thomas Benjamin,
Data Lake for Enterprises


Usos: Análisis de logs, sensores IoT -
Procesamiento con Spark - Proyectos
exploratorios

Ejemplos: Azure Data Lake, AWS S3,
HDFS




Características

- Flexible: acepta datos estructurados, semi y no estructurados.
- Ideal para ciencia de datos y machine learning.
- Basado en almacenamiento distribuido
- Diseñado para grandes volúmenes de datos.
- Bajo costo de almacenamiento.
- Alta escalabilidad



¿Cómo se organizan los datos en un Data Lake?



Este enfoque por zonas permite trazabilidad, control de calidad y una evolución progresiva de los datos hacia el análisis.



¿Qué pasa si guardamos todo sin control?



Data Lake - Ventajas y Desventajas

Ventajas

- **Almacena cualquier tipo de dato** (estructurado, semi, no estructurado)
- **Escalabilidad** prácticamente ilimitada (especialmente en la nube)
- **Bajo costo por almacenamiento** (comparado con un DWH tradicional)
- **Flexibilidad** para aplicar machine learning y análisis avanzado
- **Ideal para ingesta masiva** y en tiempo real de múltiples fuentes
- **Compatible con múltiples herramientas** de análisis y visualización

Desventajas

- Puede volverse un data **swamp** si no se gestiona bien
- Requiere buen gobierno de datos para mantener calidad y trazabilidad
- La consulta de datos puede ser más lenta y menos optimizada
- No tiene modelo de datos predefinido (más complejo para usuarios no técnicos)
- Se necesita infraestructura técnica para transformar y preparar los datos
- Puede haber redundancia si no se controla bien la duplicación de datos



Lakehouse

¿Podemos tener lo mejor de ambos mundos?



¿Qué es un Lakehouse?

El Lakehouse es una arquitectura que **combina** las funcionalidades de los **Data Lakes** (almacenamiento flexible y económico) con las capacidades de los **Data Warehouses** (consistencia transaccional, rendimiento, gobernanza).



Data Warehouse



Data Lake



Data Lakehouse



¿Qué problema resuelve un Lakehouse?

- **Elimina la duplicación de datos** entre sistemas (Lakes y Warehouses)
- **Reduce costos y complejidad de procesos** de carga tradicionales
- **Disminuye la latencia** entre la captura de datos y el análisis
- Permite procesar **datos estructurados, semi-estructurados y no estructurados** en una misma arquitectura
- **Mejora la gobernanza de datos** mediante catálogos y control de versiones
- Facilita el trabajo de **equipos multidisciplinarios** (data engineers, analysts, científicos de datos) sobre una fuente común
- **Escala horizontalmente** sin necesidad de rediseñar la arquitectura



Capacidades Técnicas Clave del Lakehouse

- **Transacciones ACID:** Garantiza consistencia y control de concurrencia
- **Time Travel:** Permite acceder a versiones históricas de los datos
- **Catálogo de Metadatos:** Gestión centralizada para múltiples motores
- **Separación de cómputo y almacenamiento:** Escalabilidad independiente
- **Soporte nativo para ML:** Entrenamiento sin mover ni duplicar datos

Ejemplo: Databricks + Delta Lake



Formatos comunes en un Lakehouse

Tipo de Formato	Ejemplo	Características Clave	Casos de Uso Típicos
Columnar	Parquet, Delta Lake	- Alta compresión - Lectura selectiva de columnas - Ideal para grandes volúmenes de datos	Consultas analíticas, dashboards, machine learning
Por filas	Avro	- Escritura rápida y secuencial - Buen para procesamiento de eventos - Autodescriptivo	Streaming, ingestión de logs, sistemas de mensajería



**Todo es Lakehouse
ahora**

**El DWH nunca va a
morir**



Comparación y toma de decisiones

A photograph of three business professionals standing on a wide, modern staircase. On the left, a man in a blue blazer and light blue shirt stands with his hands in his pockets. In the center, a woman in a light grey blazer and yellow top stands with her hands on her hips. On the right, another man in a light blue blazer and light blue shirt stands with his hands in his pockets. The background shows the architectural details of the staircase and building.

Comparando las arquitecturas

Criterio	Data Warehouse	Data Lake	Lakehouse
Tipo de datos	Estructurados	Todos	Todos
Costo	Medio / Alto	Bajo	Medio
Flexibilidad	Baja	Alta	Alta
Gobernanza	Alta	Baja	Alta
Casos de uso	BI, reportes	ML, exploración	BI + ML
Ejemplo	BigQuery	Azure Data Lake	Databricks Deltalake



¿Qué arquitectura utilizarían en cada caso?

CASO A

Los equipos de negocio y de ciencia de datos trabajan por separado y duplican información constantemente. La empresa quiere que ambos usen los mismos datos, desde dashboards hasta modelos de machine learning, y reaccionar rápidamente a lo que ocurre en el negocio.

CASO B

La empresa está recolectando grandes volúmenes de información de sensores, aplicaciones y contenido multimedia. Aún no sabe exactamente cómo usarlos, pero quiere guardarlos completos para explorarlos más adelante en proyectos de inteligencia artificial.

CASO C

El equipo ejecutivo revisa cada mañana los mismos dashboards de ventas y finanzas. Cuando los números no coinciden entre áreas o el reporte demora, se detienen decisiones clave. Necesitan resultados consistentes, rápidos y confiables para todos.

¿Qué arquitectura usarías en un banco digital?



A photograph of three people—two men and one woman—standing on a wide, modern concrete staircase. The man on the left is wearing a blue blazer over a light blue shirt and dark trousers. The woman in the center is wearing a light grey blazer over a mustard yellow top and dark blue trousers. The man on the right is wearing a light blue blazer over a light blue shirt and dark trousers. They are all smiling and looking towards the camera. The background shows the architectural details of the staircase and building. The text "Caso Aplicado" is overlaid in the center in a large, white, sans-serif font.

Caso Aplicado

A hand is shown in the lower right, pointing towards a glowing network diagram on the left. The diagram consists of white nodes connected by lines, set against a dark blue background with a bright blue glow emanating from the nodes. The text is centered in the middle of the image.

Diseño de componente dimensional para un Data Warehouse

Diseño de componente dimensional para un DWH

Objetivo:

- Mejorar la capacidad de análisis de ventas a nivel regional, de producto y de cliente, a fin de identificar patrones de consumo, oportunidades de crecimiento y optimizar decisiones comerciales en mercados internacionales.

Justificación:

Se requiere una estructura analítica que permita responder rápidamente preguntas como:

- ¿Qué productos se venden más en cada región?
- ¿Qué clientes generan mayores ingresos?
- ¿Cómo varían las ventas día a día?



Diseño de componente dimensional para un DWH

Solución propuesta:

- Construcción de un componente dimensional como parte del Data Warehouse empresarial, permitiendo análisis flexibles mediante un esquema en estrella (Star Schema).

OrderDate	CustomerId	CustomerName	CustomerEmail	ProductId	ProductName	ProductCategory	RegionId	RegionName	Country	Quantity	Unitprice	TotalAmount
2025-04-01	101	Alice	alice@email.com	201	Laptop	Electronics	3	Europe	Germany	3	1000	3000
2025-04-02	102	Bob	bob@email.com	202	Smartphone	Electronics	6	Oceania	Australia	3	700	2100
2025-04-03	103	Charlie	charlie@email.com	203	Monitor	Electronics	3	Europe	Germany	1	300	300
2025-04-04	104	Diana	diana@email.com	204	Keyboard	Accessories	6	Oceania	Australia	1	100	100
2025-04-05	105	Ethan	ethan@email.com	205	Headphones	Accessories	5	Africa	Nigeria	1	150	150
2025-04-06	106	Fiona	fiona@email.com	206	Gaming Console	Electronics	2	South America	Brazil	2	500	1000
2025-04-07	107	George	george@email.com	207	Smartwatch	Accessories	3	Europe	Germany	1	250	250
2025-04-08	108	Hannah	hannah@email.com	208	Tablet	Electronics	4	Asia	Japan	2	600	1200
2025-04-09	109	Ian	ian@email.com	209	Webcam	Accessories	2	South America	Brazil	2	80	160





Takeaways

- No se trata de tener datos, sino de organizarlos bien.
- Cada arquitectura responde a un problema distinto.
- Data Warehouse = control y estructura.
- Data Lake = flexibilidad y escala.
- Lakehouse = equilibrio moderno
- La arquitectura correcta depende del caso de negocio.

¡Gracias!



UTEC Posgrado