



**UTEC** Posgrado

CURSO

# INGENIERÍA DE DATOS

Angel Tintaya, Tech MBA  
Senior Data Engineer



The background of the image features a dark blue field with a glowing network of white lines and dots, resembling a data or neural network. In the lower foreground, a human hand is visible, with the index finger pointing towards the left, where a bright light source creates a lens flare effect. The text is centered in the upper half of the image.

# ARQUITECTURA Y ESTRATEGIA DE DATA ENGINEERING



# ENFOQUES MODERNOS:


# DATA FABRIC Y DATA MESH

# ¿Qué pasa en una empresa cuando el equipo de datos se convierte en un cuello de botella?



## Qué aprenderemos hoy


- Qué son Data Fabric y Data Mesh
- Qué problemas buscan resolver
- Diferencias entre enfoque centralizado y descentralizado
- Cómo impactan en la organización
- Cuándo usar cada enfoque





## AGENDA DE HOY

- The road so far
- Enfoques Modernos
- El problema: escalar el uso de datos
- Data Fabric
- Data Mesh
- Comparación
- Caso práctico








The road so far





- Fundamentos de Data Engineering
- Diferencias entre Data Engineering, Data Discovery y Data Science
- Arquitecturas modernas de datos: Data Warehouses, Data Lakes y Lakehouse
- **Data Mesh y Data Fabric: enfoques modernos para la gestión de datos**
- Patrones de ingestión de datos: Batch, Streaming y Lambda/Kappa Architectures



# Enfoques modernos

UTECH VENTURES

PANEL UV

UIS 20

utech

repositorio

# ¿Por qué repensar nuestras arquitecturas de datos?



Volumen y variedad de datos en crecimiento



Multiplicidad de fuentes (Nube, on-premise, APIs)



Fricción entre equipos de negocio, ciencia de datos e ingeniería



Modelos de IA no llegan a producción por falta de datos confiables



A background image showing two women in an office. The woman on the left is smiling broadly, looking towards the right. The woman on the right is also smiling, looking at a computer screen and pointing at it with her right hand. The image is dimmed to serve as a background for the text.

# El problema: Escalar el uso de datos

# ¿Por qué los equipos de datos no logran escalar en muchas empresas?



A photograph of three people—two men and one woman—standing on a wide, modern concrete staircase. The man on the left is wearing a blue blazer over a light blue shirt and dark trousers. The woman in the center is wearing a light grey blazer over a mustard yellow top and dark blue trousers. The man on the right is wearing a light blue blazer over a light blue shirt and dark trousers. They are all smiling and looking towards the camera. The background is a modern building with concrete walls and stairs. The text "Data Fabric" is overlaid in a large, white, sans-serif font across the center of the image.

# Data Fabric



# ¿Y si en lugar de mover los datos...



... conectamos todo?





# ¿Qué es Data Fabric?

Data Fabric es un **enfoque arquitectónico y tecnológico** que **permite romper los silos** de datos, **facilitando el acceso**, la ingesta, integración y compartición de datos **de forma gobernada** a lo largo de toda la organización, **sin importar dónde residan los datos**: ya sea en entornos on-premise, múltiples nubes o sistemas híbridos.



# Componentes de un Data Fabric

1. Catálogo y metadatos activos
2. Conectividad y virtualización de datos
3. Orquestación e integración inteligente
4. Gobernanza de datos y políticas de seguridad
5. Autoservicio para usuarios (data consumers)
6. Observabilidad y automatización con IA



# Componentes de un Data Fabric

| Componente                                   | Definición                                                                                               | Funciones Clave                                                                            | Tecnologías                                                                              |
|----------------------------------------------|----------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------|
| 1. Catálogo y Metadatos Activos              | Catálogo con metadatos técnicos, operacionales y de negocio que activa acciones en función de los datos. | Linaje, clasificación, gobernanza, descubrimiento, scoring de calidad, alertas de cambios. | Datahub, Apache Atlas, Atlan, Unity Catalog (Databricks), Microsoft Pureview (Microsoft) |
| 2. Conectividad Distribuida y Virtualización | Acceso a múltiples fuentes de datos sin moverlos, usando vistas lógicas sobre fuentes heterogéneas.      | Unifica el acceso, evita duplicidad de datos, reduce creación de pipelines.                | Trino, Denodo, Dremio                                                                    |

## Componentes de un Data Fabric

| Componente                | Definición                                                                                              | Funciones Clave                                                  | Tecnologías                                                                                 |
|---------------------------|---------------------------------------------------------------------------------------------------------|------------------------------------------------------------------|---------------------------------------------------------------------------------------------|
| 3. Orquestación de datos  | Automatización del movimiento, transformación y validación de datos.                                    | Flujos de trabajos empaquetados, Agendamiento, Alertas de fallos | Apache Airflow, dbt, Dagster, Prefect                                                       |
| 4. Gobernanza y seguridad | Control de accesos, cumplimiento normativo (GDPR), gestión de datos sensibles, políticas de privacidad. | Políticas de accesos basados en roles, tagging, auditorías       | Denodo, Collibra, Apache Ranger, Unity Catalog (Databricks), Microsoft Pureview (Microsoft) |

## Componentes de un Data Fabric

| Componente                                | Definición                                                                                        | Funciones Clave                                                               | Tecnologías                                                                  |
|-------------------------------------------|---------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------|------------------------------------------------------------------------------|
| 5. Autoservicio para usuarios             | Permite a los usuarios descubrir, acceder y usar datos sin depender de equipos técnicos.          | Descubrimiento, previsualización, desarrollo code o no code.                  | Databricks Notebooks (Databricks), Google Data Studio, Looker, Power BI      |
| 6. Observabilidad y automatización con IA | Monitorea datos y pipelines en tiempo real, detecta anomalías y previene errores automáticamente. | Monitoreo de: Latencia, Volumen, Calidad, Frecuencia de acceso, uso, errores. | Great Expectations (GX), Datahub, Databand (IBM), Unity Catalog (Databricks) |

# Casos de uso de Data Fabric

Gobierno de datos en entornos  
regulados (ej. banca)

Customer 360  
(sin importar fuente)

Data sharing entre unidades de  
negocio

Aceleración de analítica  
e IA





“Data Fabric no reemplaza todo lo que ya tienes. Lo conecta, organiza y hace inteligente para que realmente puedas escalar el valor del dato.”



# Data Fabric - Ventajas y Desventajas

## Ventajas

- **Integración unificada:** Conecta datos desde múltiples fuentes (on-premise, nube, bases relacionales, no relacionales).
- **Acceso transparente:** Los usuarios acceden a los datos sin preocuparse por dónde están o cómo están almacenados.
- **Escalable y flexible:** Se adapta al crecimiento de datos y a diferentes plataformas tecnológicas.
- **Gobernanza centralizada:** Facilita la seguridad y el control con políticas unificadas.

## Desventajas

- **Alto costo inicial:** requiere inversión en herramientas, infraestructura y configuración.
- **Curva de aprendizaje:** puede ser compleja para equipos sin experiencia en integración avanzada.
- **Enfoque centralizado:** puede generar cuellos de botella si todo pasa por un equipo central.
- **Falta de contexto local:** los equipos no siempre tienen control sobre cómo se usan sus propios datos.

# ¿Esto soluciona el problema organizacional...



... o solo el técnico?



A background image showing two women in an office. The woman on the left is smiling broadly, looking towards the right. The woman on the right is also smiling, looking at a computer screen and pointing at it with her right hand. The office environment is blurred in the background.

# Data Mesh

# ¿Y si el problema no es la tecnología... sino cómo organizamos los equipos?



# ¿Por qué Data Mesh?

## Las arquitecturas centralizadas no escalan bien

- Crece el volumen, la complejidad y la demanda... pero la solución tradicional se vuelve rígida.

## El equipo central de datos se convierte en un cuello de botella

- Todos dependen de un mismo equipo para acceder, transformar o entregar datos.

## Los dominios necesitan autonomía

- Los equipos que generan y usan los datos deben tener más control para responder con agilidad.



# ¿Qué es Data Mesh?

Data Mesh es un **enfoque sociotécnico descentralizado** que permite a distintos equipos compartir, acceder y **gestionar datos analíticos de forma eficiente en entornos complejos y de gran escala**, ya sea al interior de una organización o en colaboración con otras.



# Principios del Data Mesh

Domain  
Ownership

Data as a  
Product

Self-Serve  
Data  
Platform

Federated  
Governance







# Principio 1: Domain Ownership

# Domain Ownership

**Delegar la propiedad de los datos analíticos** a los dominios de negocio más cercanos a los datos, ya sean a **quienes lo generan** o a **quienes más los consumen**.

Organizar los datos según los dominios que representan, **gestionando de manera autónoma su ciclo de vida** dentro de cada dominio.



# Caso: Dominio de datos en una concesionaria automotriz



## Dominios basados en ORIGEN DE DATOS


| Dominio de datos    | Responsable              | Datos Incluidos                             |
|---------------------|--------------------------|---------------------------------------------|
| Venta de vehículos  | Área de Ventas           | Ventas realizadas, cotizaciones, contratos. |
| Taller y Post Venta | Área de Servicio Técnico | Citas, mantenimientos, repuestos utilizados |
| CRM / Markerting    | Área de Marketing        | Leads, campañas, seguimientos               |

## Dominios basados en CONSUMO DE DATOS

| Dominio de datos           | Responsable                 | Datos Consumidos                       |
|----------------------------|-----------------------------|----------------------------------------|
| Inteligencia Comercial     | BI                          | Ventas +<br>marketing +<br>postventa   |
| Experiencia del<br>Cliente | CX / Atención al<br>Cliente | CRM +<br>postventa + NPS +<br>reclamos |
| Performance<br>Operativa   | Operaciones                 | Ventas + servicios +<br>logística      |


## Domain Ownership - Motivaciones

Escalar el intercambio de datos al ritmo del crecimiento organizacional




Más fuentes de datos, mayor número de consumidores de datos, mayor diversidad de casos de uso de los datos.

Facilitar cambios continuos



Al estar localizados en cada dominio.


Fomentar agilidad



Reduciendo dependencias y cuellos de botella centrales.


# Domain Ownership - Motivaciones

Mejorar la veracidad de los datos en el negocio



Al reducir la brecha entre su origen real, donde y cuando son utilizados para el análisis.

Fortalecer la resiliencia de las soluciones analíticas y de machine learning



Al eliminar procesos intermedios complejos en los pipelines de datos.







# Principio 2: Data as a Product



# Data as a Product

Implica que los **datos generados** en los dominios de negocio se comparten directamente con los usuarios de datos (analistas, científicos de datos, etc.) **como si fueran productos listos para usar.**

## Características:


- Descubrible
- Localizable
- Comprensible
- Confiable y veraz
- Accesible nativamente
- Interoperable y componible
- Valioso por sí mismo
- Seguro

“Cada data product es autónomo y su modelo y ciclo de vida son manejados independientemente de otros”




# Data as a Product - Motivaciones

Eliminar la formación de silos de datos transformando la relación de los equipos con los datos



Pasan de ser elementos aislados a productos compartidos entre dominios.

Impulsar una cultura de innovación basada en datos




Facilitando una experiencia fluida para descubrir, acceder y utilizar datos de alta calidad entre equipos, sin fricciones.




# Data as a Product - Motivaciones

Aumentar la resiliencia al cambio



Aislando los data products para que modificaciones en uno no afecten a otros.

Maximizar el valor de los datos



Facilitando su uso y reutilización más allá de los límites del dominio o incluso de la organización.



# Data as a Product

## Dominio de Marketing

- **Data Product:** customer\_segmentation
- **Descripción:** Asignación de segmentos de comportamiento y valor a cada cliente para personalización de campañas.
- **Expuesto en:** Databricks (Delta Lake) + Power BI
- **Descubierto vía:** Unity Catalog + catálogo de productos de datos en Confluence.

## Detalles:

- Tablas: core\_customers, cluster\_profiles, segmented\_customers, segment\_campaign\_performance
- Actualizado mensualmente mediante pipelines en PySpark.
- Modelo de clustering versionado con MLflow.
- Power BI conectado a la tabla de performance para medir la efectividad de cada segmento.



# Principio 3: Self-Serve Platform

# Self-serve Data Platform

Es una plataforma de autoservicio que permite a los equipos de dominio crear, compartir y consumir productos de datos sin fricciones.

Gestiona el ciclo de vida completo de cada producto de datos

Conecta productos a través de una malla confiable e interoperable


Facilita la descubribilidad, trazabilidad y reutilización de los datos

Empodera a productores y consumidores sin depender de equipos centrales




# Self-serve Data Platform - Motivaciones

Reduce el costo total de una gestión descentralizada de datos



Reutiliza servicios comunes y reduce duplicidades técnicas.

Simplifica la complejidad técnica, aliviando la carga cognitiva de los equipos de dominio




Proporciona herramientas, automatizaciones y estándares comunes que abstraen detalles técnicos complejos.




# Self-serve Data Platform - Motivaciones

Activa a más desarrolladores, sin necesidad de alta especialización en datos



Ofrece experiencias guiadas para crear y operar data products sin necesidad de ser experto en datos.

Automatiza la gobernanza, asegurando seguridad y cumplimiento



Incorpora políticas de gobernanza como código, ejecutadas por la plataforma.





# Self-serve Data Platform - Ejemplo

## 1. Acceso a Datos (Unity Catalog)

- Gobernanza centralizada de los datos.
- Equipos acceden a datos desde Databricks.

## 2. Desarrollo de Pipelines (Airflow + GitOps)

- Airflow orquesta tareas de transformación y procesamiento de datos.
- GitOps gestiona versiones y despliegue automático de pipelines.

## 3. Creación de Data Products (Databricks)

- Equipos crean data products (tablas Delta, modelos ML, etc.).
- Acceso a estos productos a través de APIs, dashboards o consultas SQL.

## 4. Monitoreo y Validación Continua

- Validación y monitoreo de pipelines y modelos en tiempo real.
- Uso de MLflow para seguimiento de experimentos.





# Principio 4: Federated Governance

# Federated Governance

Crea un modelo de gobernanza con **decisiones y responsabilidades compartidas** entre:

- Representantes de dominios
- Equipo de plataforma de datos
- Expertos en temas clave (legal, seguridad, compliance)


Equilibra la autonomía y la agilidad de los dominios con la interoperabilidad global del data mesh.

Su ejecución apoya fuertemente en la autorización de políticas detalladas para cada producto de datos, mediante los servicios de la plataforma de datos.




# Federated Governance - Motivaciones

Obtener mayor valor al correlacionar productos de datos independientes pero interoperables.



Mediante reglas y estándares comunes que garantizan la interoperabilidad entre data products.

Evitar incompatibilidades y desconexiones entre dominios descentralizados.




Con una estructura federada de decisión que coordina los dominios sin centralizar el control.




# Federated Governance - Motivaciones

Permitir el cumplimiento transversal de requisitos de seguridad, privacidad y normativas.



Codificando e integrando reglas de cumplimiento directamente en los data products a través de la plataforma.

Reducir el esfuerzo manual de coordinación entre dominios y funciones de gobernanza



Automatizando políticas y validaciones desde la plataforma para facilitar la gobernanza continua y escalable.



# Federated Governance - Ejemplo

## Contexto:

Empresa con tres dominios (Finanzas, Marketing, Logística)

## Caso:

Un analista de **Finanzas** necesita acceder a datos de campañas del dominio **Marketing**.

## Flujo:

- El **equipo de Gobernanza** define políticas globales (roles, clasificaciones, seguridad).
- El ***data steward*** de Marketing evalúa la solicitud según esas políticas.
- Se aprueba **acceso limitado** a una vista agregada sin exponer datos sensibles.
- Unity Catalog **aplica las reglas automáticamente** según el rol del usuario.



# Federated Governance - Ejemplo

## Resultados:


- Marketing mantiene control sobre sus datos.
- Gobernanza asegura cumplimiento y trazabilidad.
- Acceso federado, seguro y auditado.



# Modelo Operativo de los Principios de Data Mesh







# Data Mesh - Ventajas y Desventajas

## Ventajas

- **Descentralización efectiva:** cada dominio gestiona sus propios datos con autonomía.
- **Escalabilidad organizacional:** elimina el cuello de botella del equipo central al distribuir la responsabilidad.
- **Data as a Product:** mejora la calidad, trazabilidad y reutilización de los datos.
- **Decisiones más ágiles:** los equipos actúan con base en datos propios, sin esperar a otros.

## Desventajas

- **Riesgo de inconsistencia:** si no hay coordinación, los datos pueden ser contradictorios entre dominios.
- **Gobernanza compleja:** se necesita un buen marco común para evitar el caos.
- **Falta de madurez tecnológica:** no todos los equipos están listos para asumir esta autonomía.
- **Mayor esfuerzo inicial:** exige inversión en formación, herramientas y cultura organizacional.

A background image showing two women in an office. The woman on the left is smiling and looking at a computer screen. The woman on the right is also smiling and pointing at the same screen. The image is dimmed to serve as a background for the text.

# Comparación

# ¿Tu empresa necesita control ...



... o escalabilidad?



## Data Fabric vs Data Mesh

| Aspecto         | Data Fabric                     | Data Mesh                                         |
|-----------------|---------------------------------|---------------------------------------------------|
| Enfoque         | Técnico<br>(automatización)     | Organizacional<br>(descentralización)             |
| Governanza      | Centralizada +<br>automatizada  | Federada y distribuida                            |
| Objetivo        | Optimizar el acceso a datos     | Escalar la producción y<br>consumo                |
| Tecnología Base | Integración de metadatos,<br>IA | Plataforma común con<br>herramientas distribuidas |



# Caso Práctico

A dark, monochromatic photograph of a modern building's interior. The scene features a wide staircase with a concrete railing on the right side. To the left, there is a glass-walled corridor or balcony. The architecture is characterized by clean lines and a mix of concrete and glass. In the background, a sign with the text "NN GEVEN NIECI RABLE" is visible. The overall atmosphere is minimalist and architectural.


# Si tuvieras que escalar datos en Spotify...



¿centralizarías o  
distribuirías?



# ¿Cómo escalar el acceso y uso de datos en Spotify sin colapsar el equipo central?



Spotify crece. Los equipos necesitan datos distintos, en tiempos distintos. El equipo de datos centralizado ya no da abasto.

¿Qué hacemos?





# Definamos Data Products para Spotify

## Formaremos 4 equipos:



### **Reproducción de música**

Registra lo que escuchan los usuarios: canciones reproducidas, tiempo escuchado, acciones (play, skip, like), dispositivo usado, etc.



### **Gestión de usuarios y suscripciones**

Administra los perfiles de usuario y sus planes (gratis/premium), datos demográficos y canales de registro.



### **Recomendaciones y ML**

Crea playlists y recomendaciones personalizadas usando datos de comportamiento, perfiles y modelos de machine learning.



### **Finanzas y pagos**

Controla cobros, ingresos, fallos de pago y costos por usuario (como licencias musicales).

## Cada equipo responde:

- ¿Qué data product crearían?
- ¿Qué equipo lo usaría? ¿Por qué?
- ¿Qué problema resuelve?



# Data Products

## Reproducción de música

**Data Product:**  
PlaybackEvents

**Consumido por:**

- Recomendaciones y ML → para entrenar modelos
- Finanzas → para estimar costos de licencias
- Usuarios → para enriquecer dashboards de perfil de usuario

## Gestión de usuarios y suscripciones

**Data Product:**  
UserProfile

**Consumido por:**

- Reproducción → para saber a quién se le puede mostrar anuncios
- Recomendaciones → para segmentar usuarios
- Finanzas → para calcular ingresos por tipo de usuario

## Recomendaciones y ML

**Data Product:**  
PersonalizedPlaylists

**Consumido por:**

- Reproducción → para mostrar en la app
- Marketing → para campañas de reactivación

## Finanzas y Pagos

**Data Product:**  
UserRevenueAndCost

**Consumido por:**

- Usuarios → para mostrar información de pago
- Reproducción y Recomendaciones → para ajustar recomendaciones si hay impagos o limitaciones



# Principios

| Principio                | Aplicación en Spotify                                                                               |
|--------------------------|-----------------------------------------------------------------------------------------------------|
| Domain Ownership         | Cada squad maneja sus propios datos (p.ej. equipo de Finanzas)                                      |
| Data as a Product        | Los datos se entregan como un producto bien empacado: claros, con instrucciones y listos para usar. |
| Self-serve Data Platform | Uso de herramientas compartidas para calidad, seguridad y monitoreo                                 |
| Federated Governance     | Normas claras aplicadas por cada dominio con autonomía                                              |

... cada dominio en Spotify es autónomo pero sigue estándares comunes ...



## Takeaways

- Los enfoques modernos buscan romper silos, no solo técnicos, también organizacionales.
- **Data Fabric** no reemplaza todo lo que ya tienes. Lo **conecta, organiza y hace inteligente** para que realmente puedas escalar el valor del dato.
- **Data Fabric** es ideal para organizaciones que necesitan **gobernanza central** con acceso distribuido.
- **Data Mesh** cambia la cultura: **distribuye la responsabilidad del dato a cada dominio**, fomenta autonomía y escalabilidad.
- **Data como producto** es un cambio clave: implica **pensar en calidad, documentación, acceso y mantenimiento**.
- La tecnología **importa**, pero más aún **la mentalidad y gobernanza**.

¡Gracias!



**UTEC** Posgrado