



UTEC Posgrado



UTEC Posgrado

Una escuela para
Early Adopters

CURSO

INGENIERÍA DE DATOS

Mg. Angel Tintaya
Senior Data Engineer



The background of the image features a dark blue gradient. On the left side, there is a network of white lines connecting small white dots, resembling a molecular or data structure. In the lower-left foreground, a hand is visible, holding a glowing blue sphere that emits a bright light. The text is centered in the upper half of the image.

DATAOPS Y AUTOMATIZACIÓN DE PROCESOS DE DATOS



IMPLEMENTACIÓN DE FLUJO DE DATOS

Si mañana tuvieras que construir un pipeline para tu empresa, ¿por dónde empezarías?




Qué aprenderemos hoy

- Cómo se construye un pipeline en Databricks
- Cómo aplicar la arquitectura Medallion
- Cómo organizar notebooks y workflows
- Qué prácticas mejoran calidad y trazabilidad
- Cómo preparar la base para un Data Product



AGENDA DE HOY

- The road so far
- ¿Cómo se construye un flujo de datos?
- Arquitectura Medallion
- Pipeline completo en Databricks
- Buenas prácticas de implementación
- Actividad práctica: Medallion Architecture
- Takeaways






The road so far



- Orquestación de flujos de datos.
- Introducción a DataOps: CI/CD para ingeniería de datos.
- ETL (Extract, Transform, Load) y ELT: conceptos y diferencias.
- **Implementación de flujos de integración de datos con herramientas modernas.**





¿Cómo se
construye un flujo
de datos?

¿Qué es un pipeline en Databricks?

Un pipeline en Databricks:

Procesa datos
desde la ingestión
hasta el análisis.

Usa **notebooks** o
scripts Python
conectados en un
workflow.

Se apoya en el
motor **Spark +**
Delta Lake para
manejar grandes
volúmenes de
datos.

Permite
trazabilidad,
versionado y
modularidad.

Componentes de un pipeline en Databricks

Un pipeline de integración de datos en Databricks incluye:

- Fuente de datos (CSV, API, SQL Server, etc.)
- Notebook de ingesta: lectura + validación
- Notebook de transformación: limpieza, enriquecimiento
- Notebook de carga: escritura a Delta Table
- Workflow (Job) con tareas secuenciales
- Alertas, retries, control de errores



¿Qué componente fallaría primero en un entorno productivo?



A photograph of three people—two men and one woman—standing on a wide, modern concrete staircase. The man on the left is wearing a blue blazer over a light blue shirt and dark trousers. The woman in the center is wearing a light grey blazer over a yellow top and dark trousers. The man on the right is wearing a light blue blazer over a light blue shirt and dark trousers. They are all smiling and looking towards the camera. The background shows the architectural details of the staircase and building. The text 'Architectura Medallion' is overlaid in white, centered on the image.

Architectura Medallion

¿Qué ocurre cuando mezclamos datos crudos, transformados y agregados en un mismo lugar?



Arquitectura Medallion en Databricks

La Medallion Architecture organiza los datos en capas secuenciales:

- **Bronze:** Datos crudos, sin transformar
- **Silver:** Datos limpios, transformados, validados
- **Gold:** Datos agregados, listos para analítica y consumo

Mejora la calidad, trazabilidad y reutilización de los datos.




Ventajas de Medallion Architecture

- Modularidad
- Trazabilidad entre capas
- Separación clara de responsabilidades
- Base para datamesh y dataproducts



Flujo típico en Medallion Architecture



UT PIPELINE URS

COMPLETO EN
DATABRICKS

Pipeline básico en Databricks

- Leer input
- Filtrar y limpiar datos
- Guardar resultados

```
1
%sql
CREATE OR REPLACE TABLE g0_catalog.default.basic_input AS
SELECT *, current_timestamp() AS inserted_at FROM read_files(
  'abfss://datalake@stdemdsai.dfs.core.windows.net/raw/airflow/G0/input.csv',
  format => 'csv',
  header => true,
  -- inferSchema => true,
  schema => 'id INT, producto STRING, cantidad INT, precio DOUBLE'
)

2
%sql
CREATE OR REPLACE TABLE g0_catalog.default.basic_transform AS
SELECT
  inp.id,
  inp.producto,
  inp.cantidad,
  inp.precio,
  inp.inserted_at,
  inp.cantidad * inp.precio AS total
FROM g0_catalog.default.basic_input inp
WHERE inp.id IS NOT NULL

3
%sql
CREATE OR REPLACE TABLE g0_catalog.default.basic_summary AS
SELECT
  producto,
  SUM(total) AS total_sum
FROM g0_catalog.default.sql_transform
GROUP BY producto
```



¿Por qué este pipeline no es escalable?



Pipeline con Medallion Architecture en Databricks

BRONZE LAYER

- Leer input.csv
- Guardar como **bronze_sql_input**

SILVER LAYER

- Leer bronze_sql_input
- Validar y limpiar datos
- Guardar como **silver_sql_transform**

GOLD LAYER

- Leer silver_sql_transform
- Agregar ventas por categoría
- Guardar como **gold_sql_summary**

Pipeline con Medallion Architecture en Databricks





Buenas prácticas en implementación de pipelines

Buenas prácticas en pipelines modernos

- Diseñar por capas (Bronze, Silver, Gold)
- Automatizar con workflows
- Validar datos entre etapas
- Usar Delta Lake para versionado y calidad
- Aplicar modularidad: un notebook por función



The background of the slide features a dark blue gradient. On the left side, there is a glowing network diagram composed of white dots connected by thin white lines, resembling a web or a data structure. A hand is visible at the bottom, with the index finger pointing towards the network diagram. The text is centered in the upper half of the image.

TAREA: Construcción de un Pipeline en Azure Databricks utilizando Medallion Architecture

Objetivo

Diseñar e implementar un pipeline de procesamiento de datos utilizando la arquitectura Medallion (Bronze → Silver → Gold) en Azure Databricks, sobre un archivo previamente cargado en Azure Data Lake. El pipeline deberá estar catalogado dentro de su dominio de datos (usando el catalog: g<número de grupo>_catalog. Ej. G0_catalog) y se aplicará al menos una transformación básica en la capa Silver.



Pasos

Lectura desde Bronze

1. Leer el archivo CSV desde el Data Lake (abfss://...) utilizando un notebook de Databricks.
2. Almacenar los datos como una tabla en el esquema Bronze, dentro de su catalog correspondiente, por ejemplo:
`g0_catalog.bronze.<nombre_tabla>`

Transformación a Silver

1. Realizar al menos una transformación sobre los datos. (Ej. Renombrar columnas, filtrar nulos, aplicar CAST, filtrar valores inválidos).
2. Almacenar los datos como una tabla en el esquema Silver, dentro de su catalog correspondiente, por ejemplo:
`g0_catalog.silver.<nombre_tabla>`

Carga a Gold

1. Crear una vista o tabla de negocio a partir de la capa Silver.
2. Almacenar los datos como una tabla en el esquema Gold, dentro de su catalog correspondiente, por ejemplo:
`g0_catalog.gold.<nombre_tabla>`

Entregable: 3 notebooks, 1 por capa.



Takeaways

- Un pipeline moderno organiza datos, transformaciones y consumo de forma trazable y mantenible.
- La arquitectura Medallion separa datos crudos, refinados y de negocio mediante las capas Bronze, Silver y Gold.
- Los Workflows permiten automatizar la ejecución y monitoreo de pipelines completos.
- La modularidad, validación y trazabilidad son tan importantes como las transformaciones de datos.
- Medallion constituye una base sólida para construir Data Products y arquitecturas Data Mesh.

¡Gracias!



UTEC Posgrado